TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI VIỆN CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG





BÁO CÁO BÀI TẬP LỚN MÔN HỌC

Lưu trữ và xử lý dữ liệu lớp LƯU TRỮ, XỬ LÝ VÀ PHÂN TÍCH ĐIỂM THI ĐẠI HỌC 2020

Nhóm: RHUST

Phan Thành Đạt	20173001
Hoàng Văn Chương	20172984
Đỗ Minh Vũ	20173471
Nguyễn Thi Bắc	20172963

I. ĐẶT VẤN ĐỀ

Xuất phát từ nhu cầu phân tích phổ điểm, dự đoán độ tin cậy trong công tác tổ chức thi trên tập dữ liệu lớn khó thực hiện một cách thủ công.

Xuất phát từ những ứng dụng thực tiễn to lớn của lưu trữ và xử lý dữ liệu lớn.


Áp dụng các kiến thức đã học vào việc xử lý một vấn đề thực tế, liên quan trực tiếp tới môn học.

II. PHÂN TÍCH BÀI TOÁN

- 1. Yêu cầu
- Trích xuất thông tin về điểm thi đại học 2020.
- Làm sạch dữ liệu
- Lưu trữ dữ liêu thu được
- Truy xuất các thông tin hữu ích từ dữ liệu đã thu thập được.

2. Quy trình thực hiện

Sơ đồ:




III. Triển khai

1. Cài đặt môi trường


Cài đặt Java 8 và Scala 2.11.8, ssh.

Cài đặt các biến môi trường:




2. Cài đặt Kafka 2.13-2.7.0


- Tåi Kafka tại:
 https://www.apache.org/dyn/closer.cgi?path=/kafka/2.7.0/kafka_2.13-2.7.0.tgz
- Khởi tạo ZooKeeperServer: kafka/bin/zookeeper-server-start.sh config/zookeeper.properties




• Khởi tạo KafkaServer: kafka/bin/kafka-server-start.sh config/server.properties



 Tạo Topic trao đổi dữ liệu: bin/kafka-topics.sh --create --topic RHUST_data -bootstrap-server localhost:9092




• Kiểm tra topic:




3. Cài đặt cluster HDFS


Một cụm cluster HDFS bao gồm 1 node-master và 2 node-worker.





4. Cài đặt cluster Spark






5. Lập trình

Phân tích cấu trúc trang web: https://thanhnien.vn/giao-duc/tuyen-sinh/2020/tra-cuu-diem-thi-thpt-quoc-gia.html

Mỗi khi tìm kiếm điểm theo số báo danh, 1 request sẽ gửi gửi lên và 1 response sẽ đc trả về:



URL gửi request:

https://thanhnien.vn/ajax/diemthi.aspx?kythi=THPT&nam=2020&city=&text=SBD&top=no

Cấu trúc response:

1class="mobile-tab-content mobile-tab-1 visible">01043333class="mobile-tab-content mobile-tab-1visible">class="mobile-tab-content mobile-tab-1 visible">9class="mobile-tab-content mobile-tab-content mobile-tab-2">class="mobile-tab-content mobile-tab-2">7.257.257.257.257.257.257.257.257.257.257.25

Để lấy được dữ liệu thì phải tách dữ liệu từ các tag html.

Cấu trúc SBD = Mã Tỉnh +abc.def

Bắt đầu từ SBD 1

a) Source code request và gửi dữ liệu vào Kafka

```
from kafka import KafkaProducer
import requests
producer = KafkaProducer(bootstrap_servers='node-master:9092')
#SBD='02074715'
SBD='02000000'
```

```
i=1
while True:
    SBD=SBD[:len(SBD)-len(str(i))]+str(i)
    x =
    requests.get('https://thanhnien.vn/ajax/diemthi.aspx?kythi=THPT&nam=2020&city=&text='+SBD+'&top=no')
    if x.text=="\n":
        break
    producer.send('RHUST_data', bytes(x.text,'utf-8'))
    producer.flush()
    i=i+1
    print(SBD)
```


b) Source code sparkstreaming và clear data:

```
import os
from scrapy import Selector
packages = "org.apache.spark:spark-streaming-kafka-0-8_2.11:2.4.7"
os.environ["PYSPARK_SUBMIT_ARGS"] = (
      "--packages {0} pyspark-shell".format(packages)
from pyspark.sql.types import *
from pyspark import SparkConf
from pyspark import SparkContext
from pyspark.streaming import StreamingContext
from pyspark.streaming.kafka import KafkaUtils
from pyspark.sql.session import SparkSession
conf = SparkConf()
conf.setMaster('spark://node-master:7077')
conf.setAppName('RHUST')
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")
ss=SparkSession(sc)
ssc = StreamingContext(sc, 3600)
KAFKA BROKER = "127.0.0.1:9092"
KAFKA_TOPIC = "RHUST_data"
schema = StructType([
     StructField('NumCity', StringType(), True),
     StructField('MSSV', StringType(), True),
StructField('Toan', StringType(), True),
StructField('Van', StringType(), True),
StructField('Ly', StringType(), True),
StructField('HoaHoc', StringType(), True),
StructField('Sinh', StringType(), True),
StructField('KHTN', StringType(), True),
     StructField('KHTN', StringType(),True),
     StructField(KHN, StringType(),True),
StructField('Su', StringType(),True),
StructField('Dia', StringType(),True),
StructField('GDCD', StringType(),True),
StructField('KHXH', StringType(),True),
StructField('NotKnow', StringType(),True),
print("RHUST")
kafkaStream =
KafkaUtils.createDirectStream(ssc,[KAFKA_TOPIC],{"metadata.broker.list":KAFKA_BROKER})
lines=kafkaStream.map(lambda value:value[1])
def handle rdd(value):
     result=[]
     City=Selector(text=value).xpath('//td[@class=""]/text()')[1].extract()[:2]
```


```
MSSV=Selector(text=value).xpath('//td[@class=""]/text()')[1].extract()
    result.append(City)
    result.append(MSSV)
    sel = Selector(text=value).xpath('//td[@class="mobile-tab-content mobile-tab-2"]')
    for i in sel:
            result.append(i.xpath("text()")[0].extract())
            result.append("-1")
    sel = Selector(text=value).xpath('//td[@class="mobile-tab-content mobile-tab-3"]')
            result.append(i.xpath("text()")[0].extract())
            result.append("-1")
coords=lines.map(lambda value: handle_rdd(value))
def store_rdd(rdd):
        if not rdd.isEmpty():
                print(type(rdd))
                df = ss.createDataFrame(rdd, schema)
df.write.format('csv').mode('append').option("header",
"true").csv("hdfs://node-master:9000/data_thpt")
                df.show()
def empty_rdd():
        print("empty RDD")
coords.foreachRDD(lambda rdd: empty rdd() if rdd.count() == 0 else store rdd(rdd))
# coords.pprint()
ssc.start()
ssc.awaitTermination()
```

6. Thực thi source code


Chạy python3 produce.py để publish dữ liệu vào kafka



Chạy spark-submit --packages org.apache.spark:spark-streaming-kafka-0-8_2.11:2.4.7 streaming.py để chạy streaming



Kiểm tra output:



7. Trực quan hóa dữ liệu

```
import numpy as np
import os
import matplotlib.pyplot as plt
packages = "org.apache.spark:spark-sql_2.12:3.0.1"
os.environ["PYSPARK_SUBMIT_ARGS"] = (
"--packages {0} pyspark-shell".format(packages)
)
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
from pyspark.sql import SQLContext
from pyspark import SparkConf
from pyspark.sql.functions import *
import pyspark.sql.functions as psf
conf = SparkConf()
conf.setMaster('spark://node-master:7077')
```

```
StructField('KHTN', StringType(), True),
StructField('KHXH', StringType(), True),
          StructField('NotKnow', StringType(), True),
StructField('NgoaiNgu', StringType(), True),
         StructField('Van', StringType(), True),
StructField('MSSV', StringType(), True),
StructField('Sinh', StringType(), True),
          StructField('Toan', StringType(), True),
StructField('Ly', StringType(), True),
StructField('Dia', StringType(), True),
print("so ban ghi:")
# print(df.count())
```

```
KHTN = df.where((col("Sinh") != -1) & (col("Ly") != -1) & (col("HoaHoo") != -
1)).select().count()

KHXH = df.where((col("GDCD") != -1) & (col("Su") != -1) & (col("Dia") != -
1)).select().count()

print(other)

print(KHXH)

print(KHXH)

diem = np.array([KHTN, KHXH])

label=["KHTN", "KHXH"]

plt.pie(diem, labels=label, startangle = 90, autopct='*.1f**')

plt.show()

# Toan = df.where(col("Toan") == 10).select().count()

# diem = np.array([Toan, Van])

# col=["Toan", "Van"]

# plt.bar(col, diem, color = 'blue', width = 0.5, alpha = 0.7)

# plt.title('So Sanh Van Toan')

# plt.xlabel('Diem')

# plt.show()

# Toan = df.where(col("GDCD") == 10).select().count()

# MogaiNgu = df.where(col("GDCD") == 10).select().count()

# NgoaiNgu = df.where(col("Sinh") == 10).select().count()

# Sinh = df.where(col("Sinh") == 10).select().count()

# Dia = df.where(col("Sinh") == 10).select().count()

# Uy = df.where(col("Sinh") == 10).select().count()

# Dia = df.where(col("Sinh") == 10).select().count()


# Su = df.where(col("Su") == 10).select().count()


# Van = df.where(col("Su") == 10).select().count()


# Van = df.where(col("Van") == 10).select().count()


# June df.where(col("June == 10).select().count()

# June
```









Van

2018

2019

2020

Năm 2015, lần đầi

2

12

273

50


0

chức vừa lấy kết c căn cứ tuyển sinh

và kỳ thi đại học ba chung (chung đề, chung đợt và chung kết quả).

Toan

Diem



Source full: https://github.com/phanthanhdat1902/SparkStreamingKafka

8. Source code scrapy cho từng máy

```
import scrapy
from thpt.items import ThptItem

class CrawlerSpider(scrapy.Spider):
    name = "crawl_point"
    MaVung="02"
    start_urls = [
        'https://thanhnien.vn/giao-duc/tuyen-sinh/2020/tra-cuu-diem-thi-thpt-quoc-gia.html'
    ]

    def parse(self, response):
        SBD='02000000'
        for i in range(201,300):
```

```
SBD=SBD[:len(SBD)-len(str(i))]+str(i)
              print(i)
scrapy.Request("https://thanhnien.vn/ajax/diemthi.aspx?kythi=THPT&nam=2020&city=&text="+SBD+"&top=no",
 allback=self.crawlLyric)
     def crawlLyric(self, response):
          item = ThptItem()
          print(response.xpath("//td[@class='']/text()")[1].extract())
          item['SBD']=response.xpath("//td[@class='']/text()")[1].extract()
          item['MaVung']=item['SBD'][0:2]
tab_2=["Toán","Ngữvăn","Vậtlí","Hóahọc","Sinhhọc"]
         tab_2=[ Todan , Ngdvan , Vatl , Todançe , Simmon
tab_2=list(enumerate(tab_2))
tab_3=["Lichsd","Địalí","GDCD","Ngoạingữ","N1"]
tab_3=list(enumerate(tab_3))
         item['N2'] = -1
item['N3'] = -1
item['N4'] = -1
item['N5'] = -1
item['N6'] = -1
          arrTr = response.xpath("//td[@class='mobile-tab-content mobile-tab-2']")
          for i in tab_2:
                 item[i[1]]=arrTr[i[0]].xpath("text()")[0].extract()
                 item[i[1]]=-1
          arrTr = response.xpath("//td[@class='mobile-tab-content mobile-tab-2']")
          for i in tab_3:
                 item[i[1]]=arrTr[i[0]].xpath("text()")[0].extract()
                 item[i[1]]=-1
          item['N1'] = item["Ngoạingữ"]
 g"]/tr')[0].xpath('td/text()').extract())
```

File item:

```
import scrapy
class ThptItem(scrapy.Item):
   MaVung=scrapy.Field()
   SBD=scrapy.Field()
   Toán = scrapy.Field()
   Ngữ văn = scrapy.Field()
   Ngoạingữ=scrapy.Field()
   N1 = scrapy.Field()
   N2 = scrapy.Field()
   N3 = scrapy.Field()
   N4 = scrapy.Field()
   N5 = scrapy.Field()
   N6=scrapy.Field()
   Vậtlí=scrapy.Field()
   Hóahọc =scrapy.Field()
   Sinhhoc=scrapy.Field()
   Lichsử=scrapy.Field()
   Địalí=scrapy.Field()
   GDCD=scrapy.Field()
```

IV. Hướng phát triển tương laiPhát triển hệ thống dự đoán điểm chuẩn đại học, dự đoán khả năng gian lận trong thi cử.